ESKADRA BIELIKA

Eskadra Bielika

Misja Druga

Kraków, 30.06.2026

Jan Andrusikiewicz

Jan Andrusikiewicz

- LLM Engineer @ Docplanner Tech
-



Cel warsztatu

Stworzenie systemu RAG opartego
o self-hosted lokalny LLM



Suwerenne i wiarygodne AI

- Rosnące ryzyko geopolityczne wymaga ograniczania zależności od zagranicznych dostawców AI.
- Pełna kontrola nad danymi, modelem i infrastrukturą.
- Wiarygodne odpowiedzi oparte na własnej wiedzy i polskim kontekście.



Kluczowe koncepcje



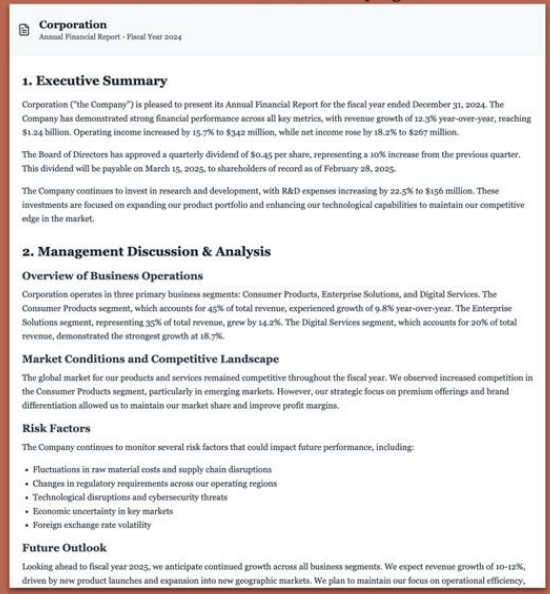
Co to RAG?

Claude with large documents

- We might want to ask Claude questions about specific sections of a large document
  - *"What risk factors does this company have?"*
- It's a private document - Claude won't have any idea what is contained in it
- How can we get Claude to understand the contents?

ANTHROP\C

Financial Doc, 800+ pages



Corporation
Annual Financial Report - Fiscal Year 2024

1. Executive Summary

Corporation ("the Company") is pleased to present its Annual Financial Report for the fiscal year ended December 31, 2024. The Company has demonstrated strong financial performance across all key metrics, with revenue growth of 12.3% year-over-year, reaching $1.24 billion. Operating income increased by 15.7% to $342 million, while net income rose by 18.2% to $267 million.

The Board of Directors has approved a quarterly dividend of $0.45 per share, representing a 10% increase from the previous quarter. This dividend will be payable on March 15, 2025, to shareholders of record as of February 28, 2025.

The Company continues to invest in research and development, with R&D expenses increasing by 22.5% to $156 million. These investments are focused on expanding our product portfolio and enhancing our technological capabilities to maintain our competitive edge in the market.

2. Management Discussion & Analysis

Overview of Business Operations

Corporation operates in three primary business segments: Consumer Products, Enterprise Solutions, and Digital Services. The Consumer Products segment, which accounts for 45% of total revenue, experienced growth of 9.8% year-over-year. The Enterprise Solutions segment, representing 35% of total revenue, grew by 14.2%. The Digital Services segment, which accounts for 20% of total revenue, demonstrated the strongest growth at 18.7%.

Market Conditions and Competitive Landscape

The global market for our products and services remained competitive throughout the fiscal year. We observed increased competition in the Consumer Products segment, particularly in emerging markets. However, our strategic focus on premium offerings and brand differentiation allowed us to maintain our market share and improve profit margins.

Risk Factors

The Company continues to monitor several risk factors that could impact future performance, including:

- Fluctuations in raw material costs and supply chain disruptions
- Changes in regulatory requirements across our operating regions
- Technological disruptions and cybersecurity threats
- Economic uncertainty in key markets
- Foreign exchange rate volatility

Future Outlook

Looking ahead to fiscal year 2025, we anticipate continued growth across all business segments. We expect revenue growth of 10-12%, driven by new product launches and expansion into new geographic markets. We plan to maintain our focus on operational efficiency,

źródło: www.anthropic.com

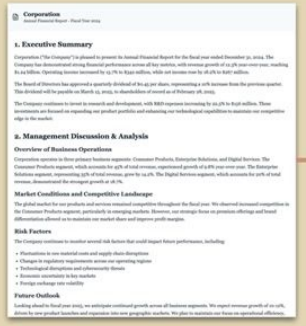
Co to RAG?

Possibly not the best solution

- There's a hard limit on how much text we can feed into Claude - the document might be too long
- Claude gets slightly less effective with very long prompts
- Larger prompts **cost more** to process
- Larger prompts **take longer** to process

ANTHROP\C

Option 1: Include the contents of the document in a prompt




```
"""
Answer the user's question about
the financial document.

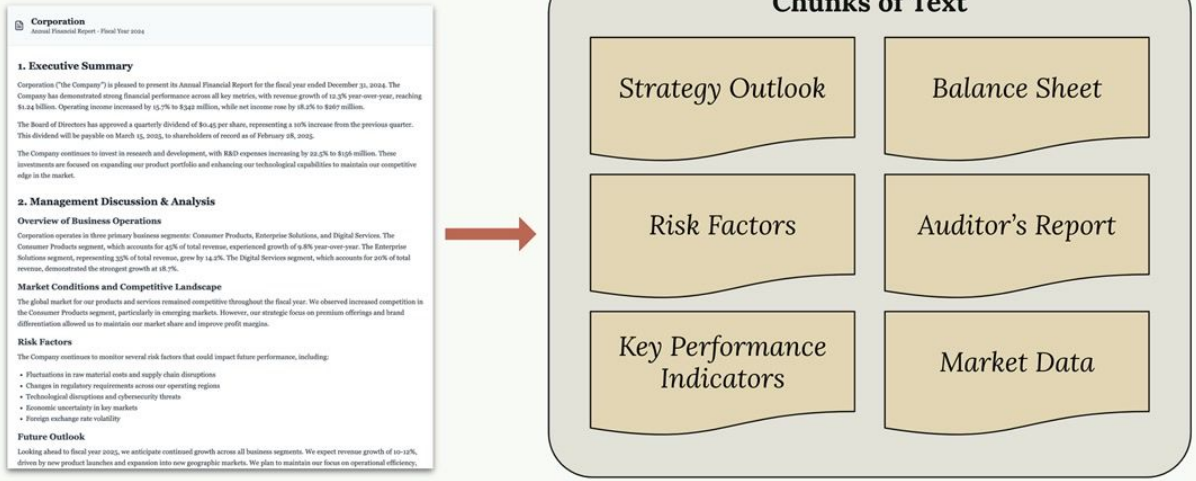
<user_question>
{user_question}
</user_question>

<financial_document>
{financial_document}
</financial_document>
"""
```

źródło: www.anthropic.com

Co to RAG?

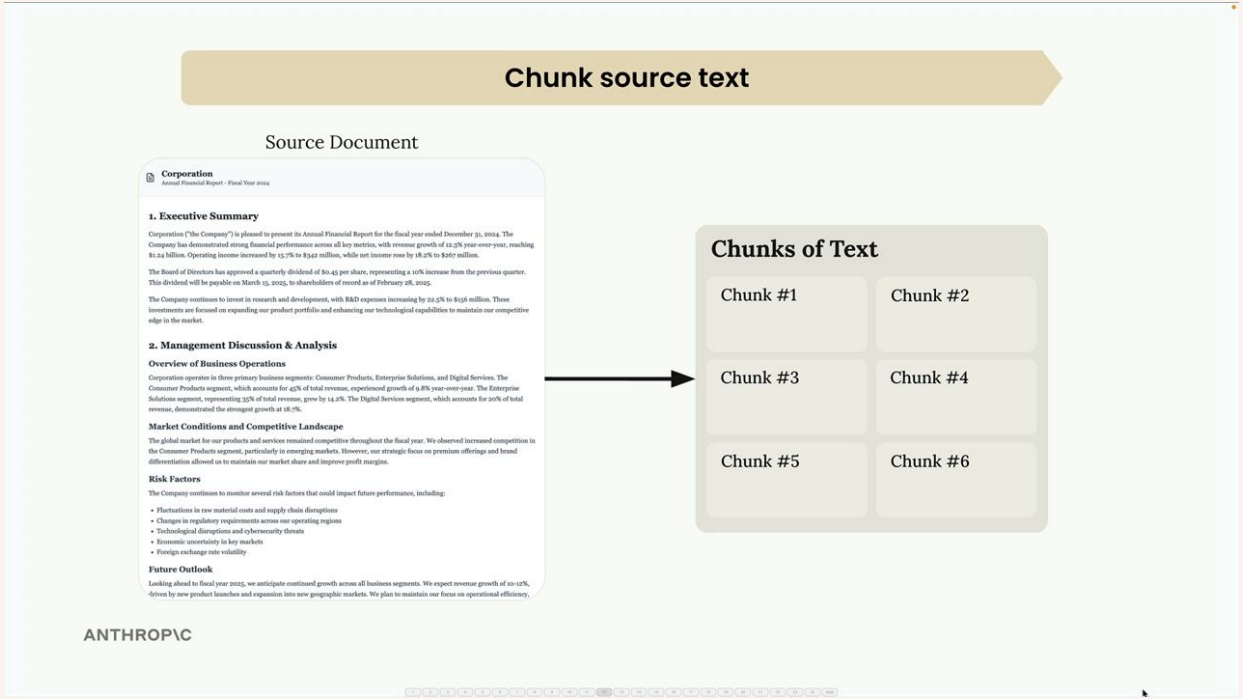
Option 2: Break the document up into many chunks. Put chunks relevant to the user's question in the prompt.



ANTHROP\C

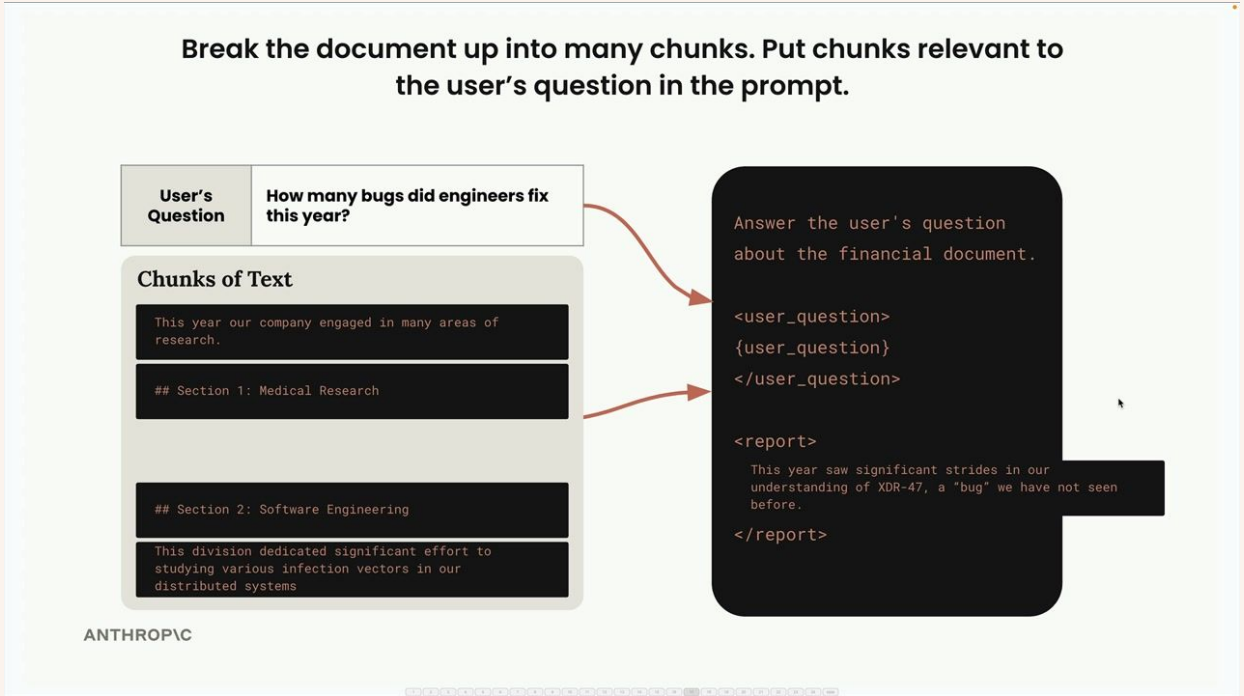
źródło: www.anthropic.com

Text chunking



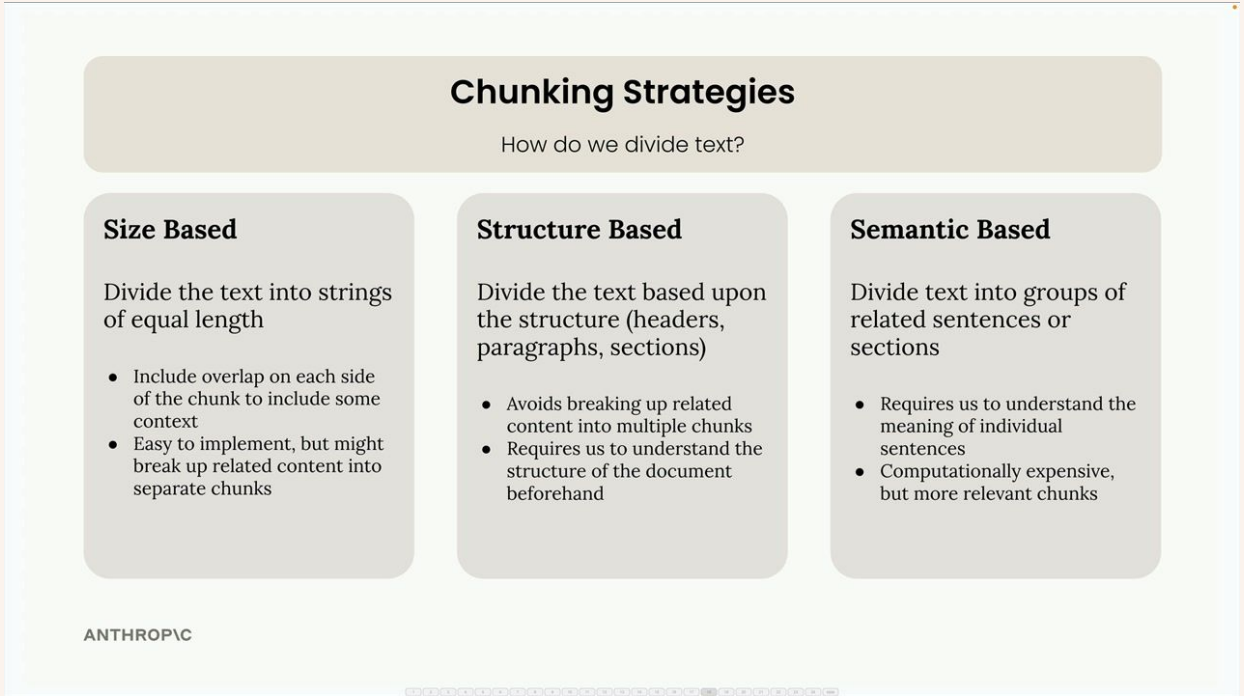
źródło: www.anthropic.com

Text chunking



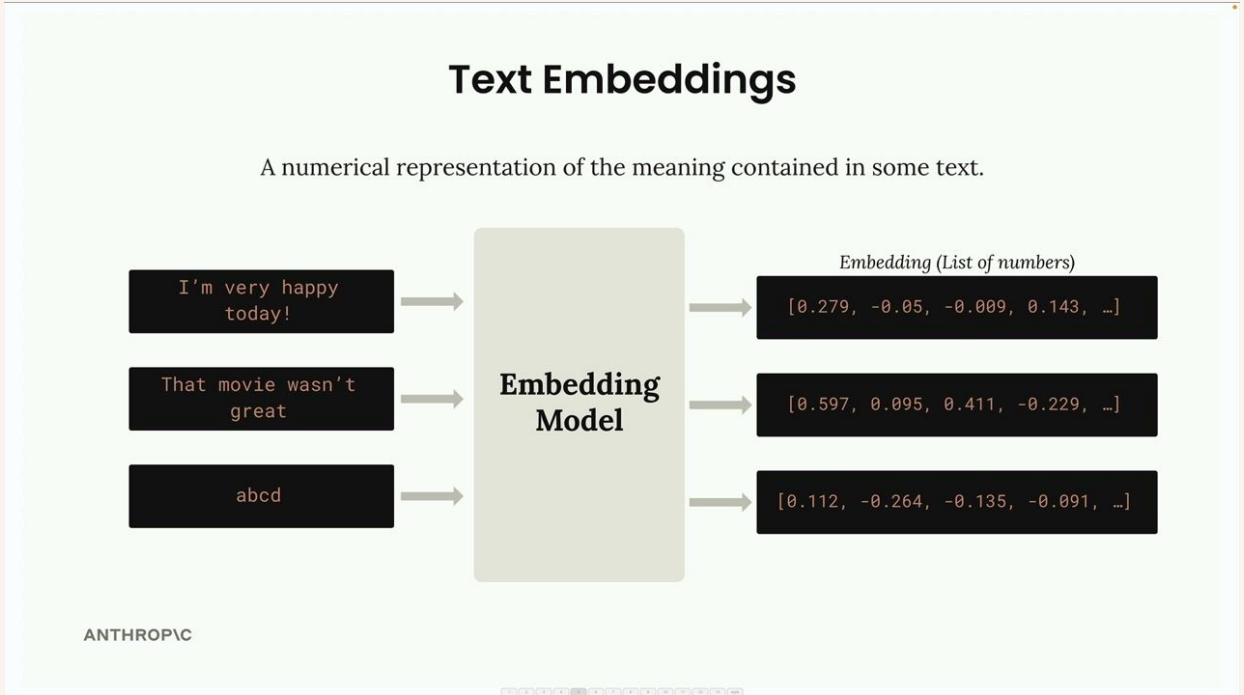
źródło: www.anthropic.com

Text chunking



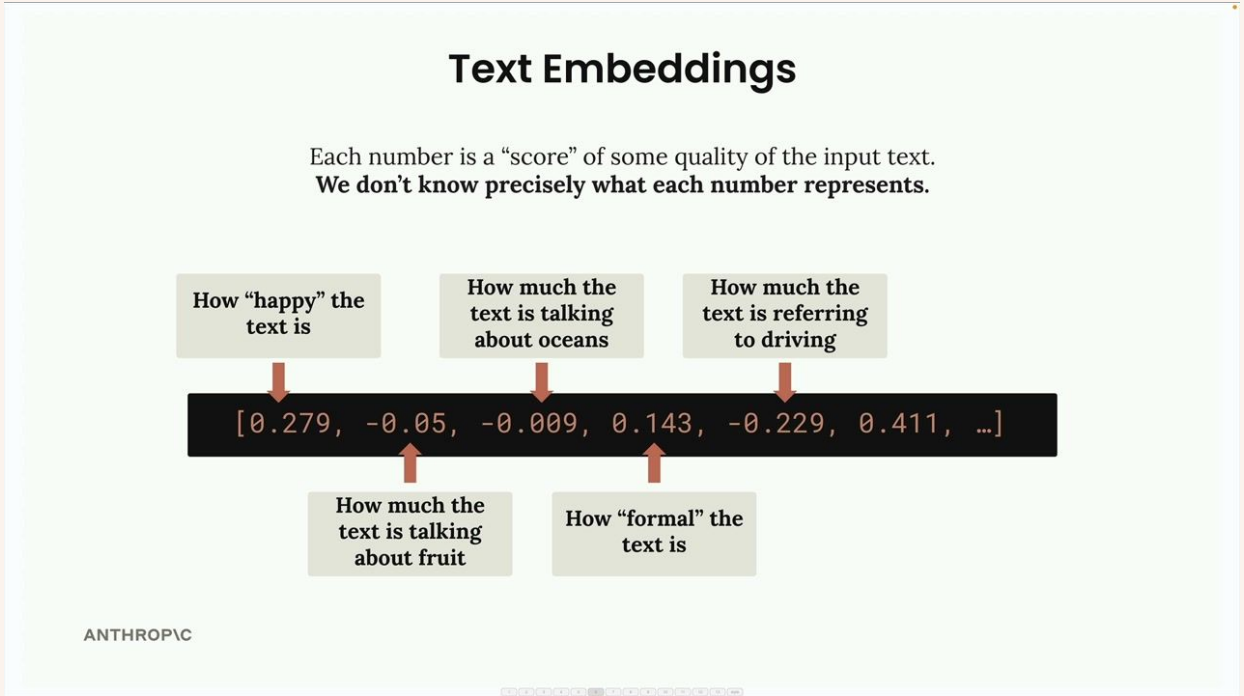
źródło: www.anthropic.com

Text embedding



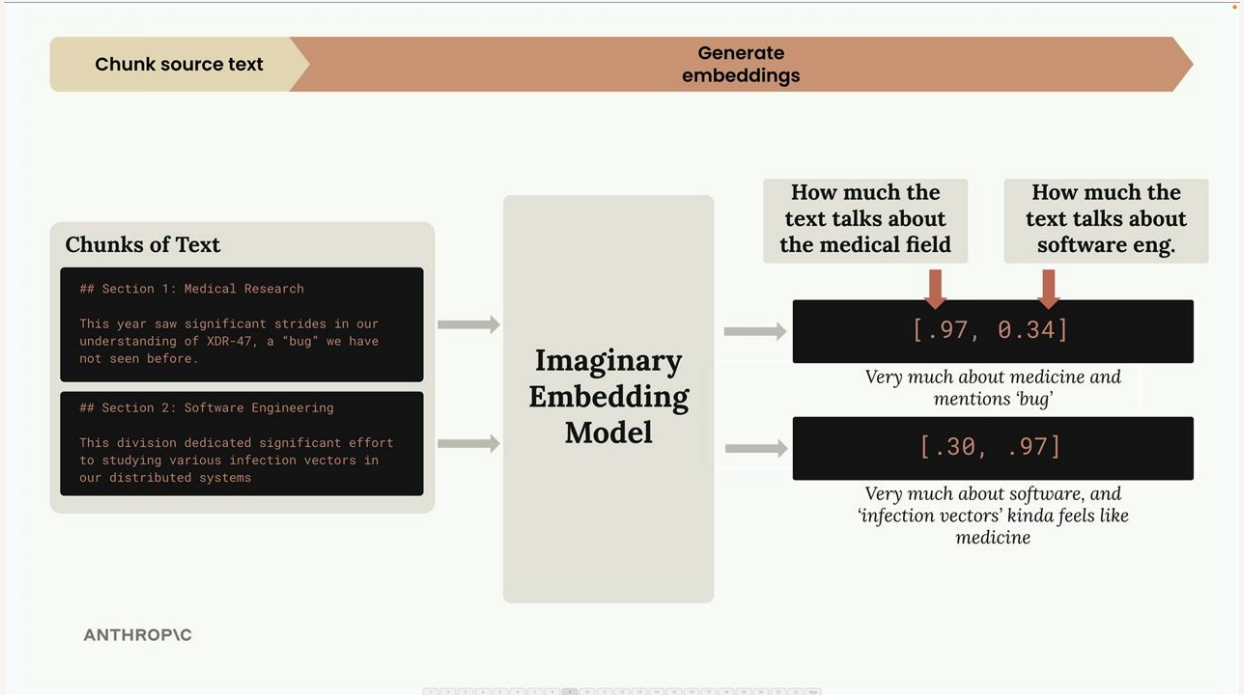
źródło: www.anthropic.com

Text embedding



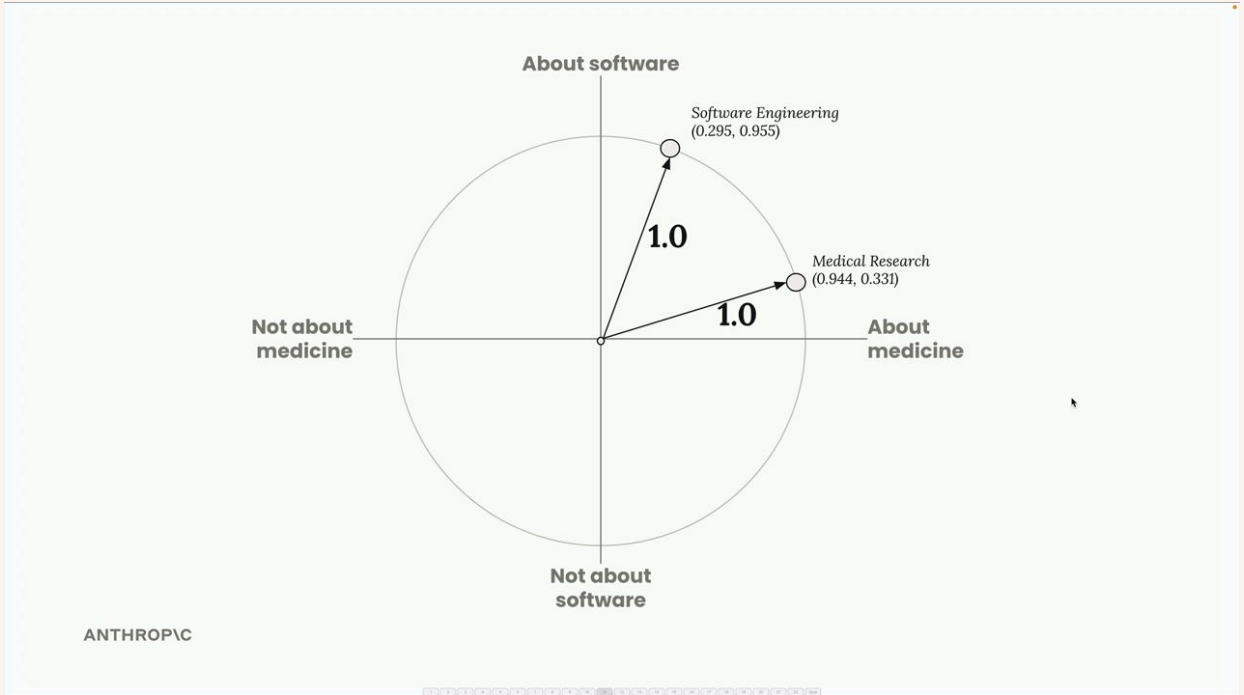
źródło: www.anthropic.com

Jak działa RAG?



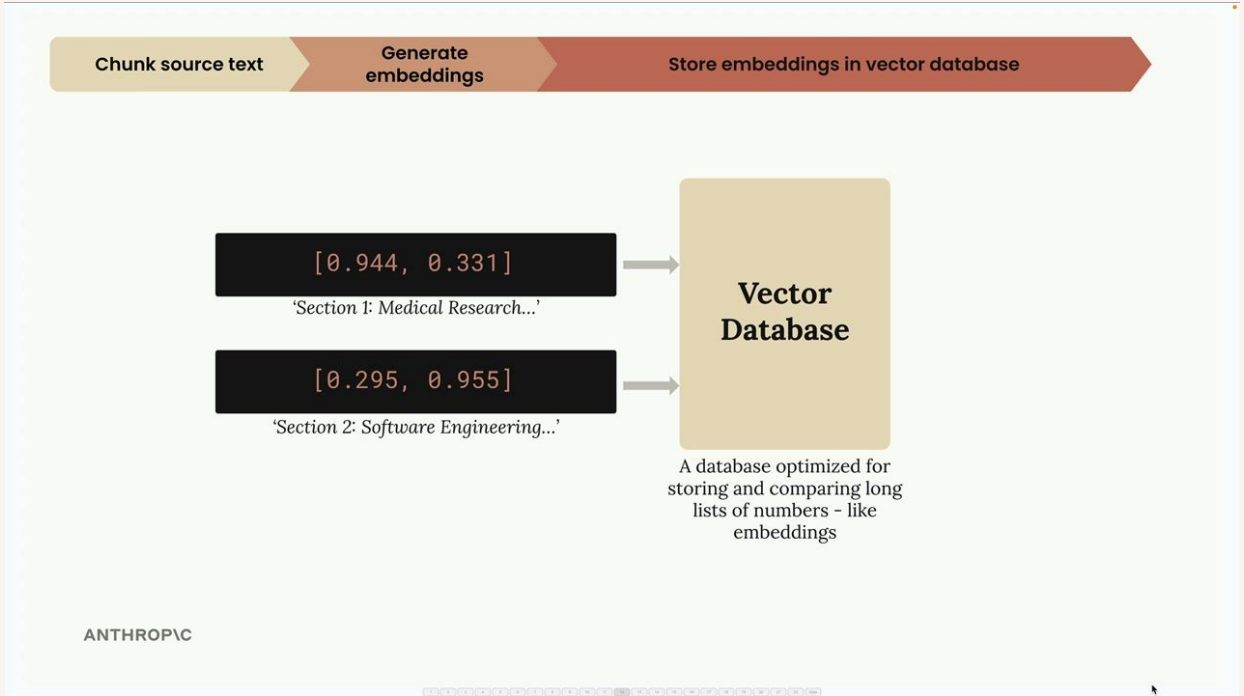
źródło: www.anthropic.com

Jak działa RAG?



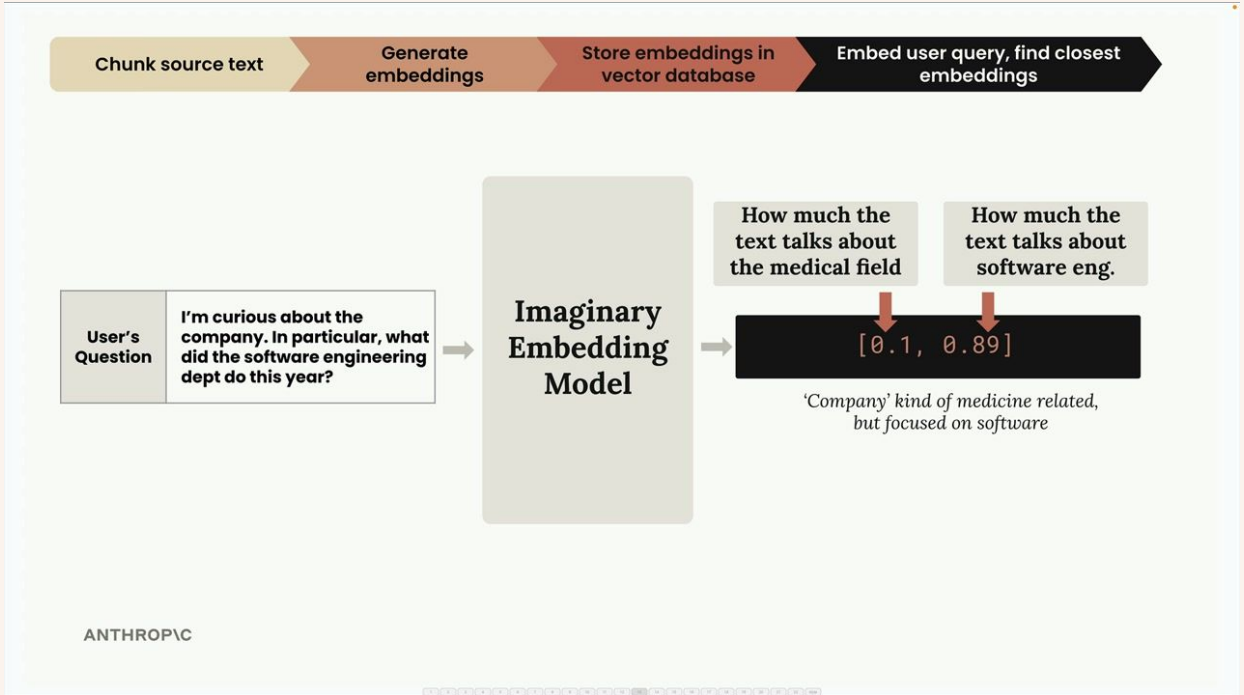
źródło: www.anthropic.com

Jak działa RAG?



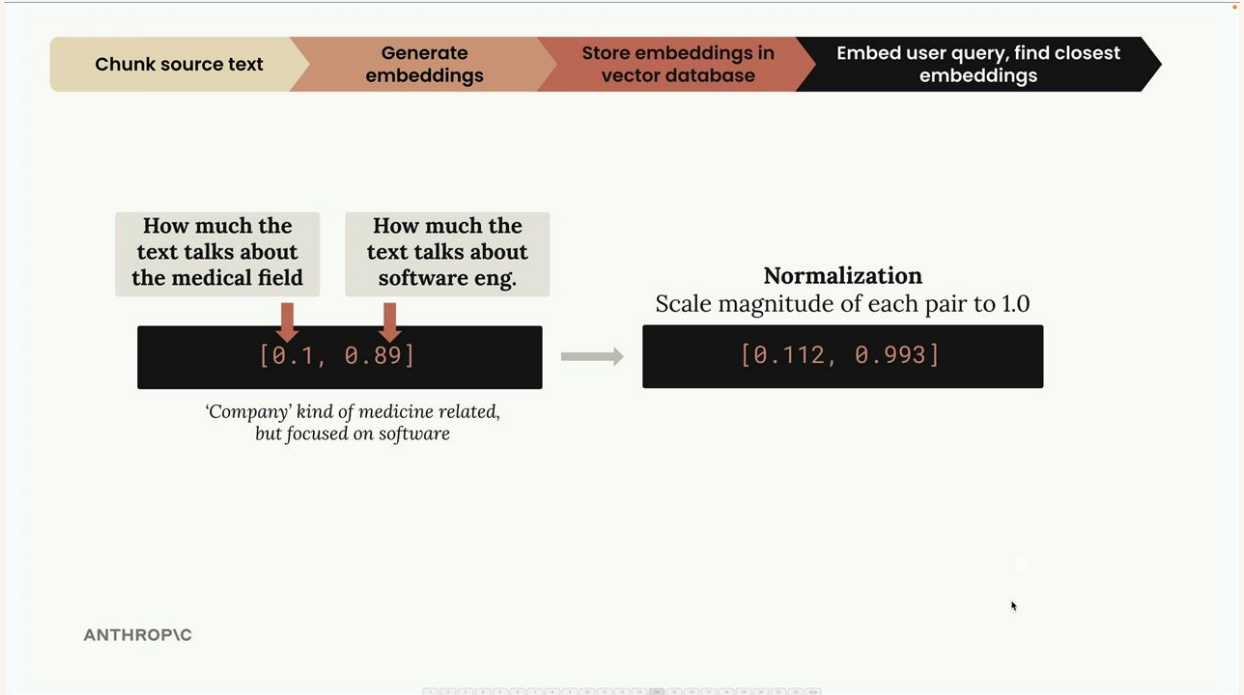
źródło: www.anthropic.com

Jak działa RAG?



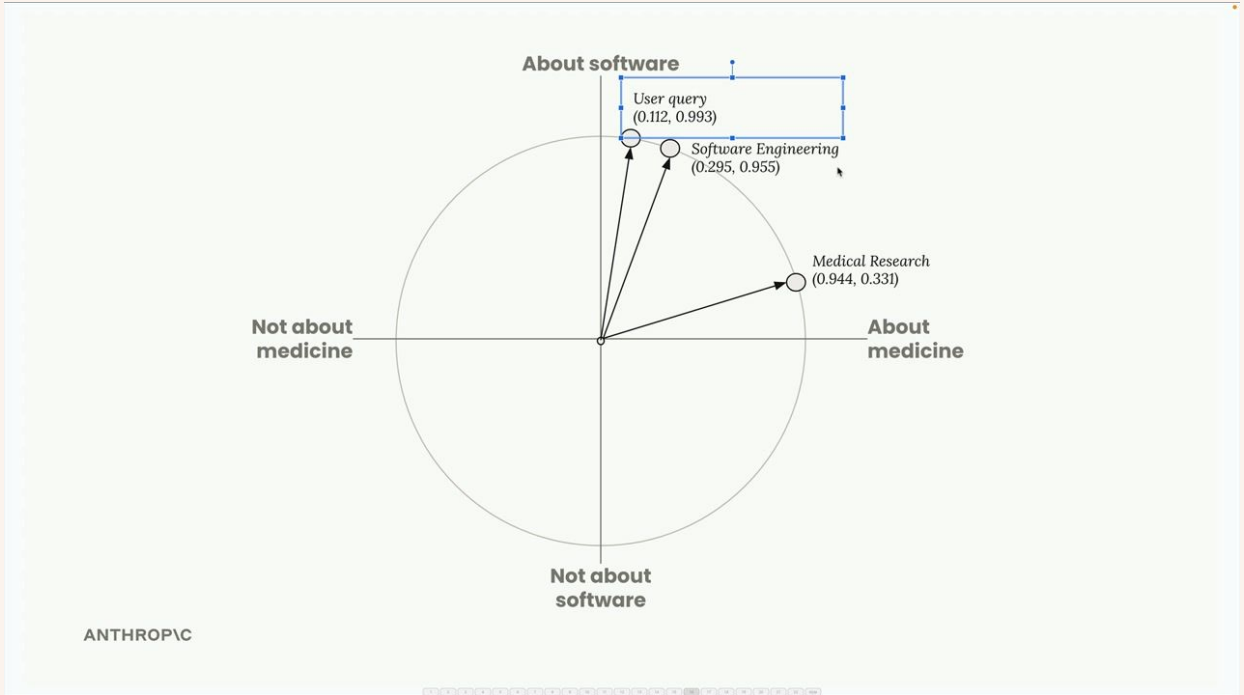
źródło: www.anthropic.com

Jak działa RAG?



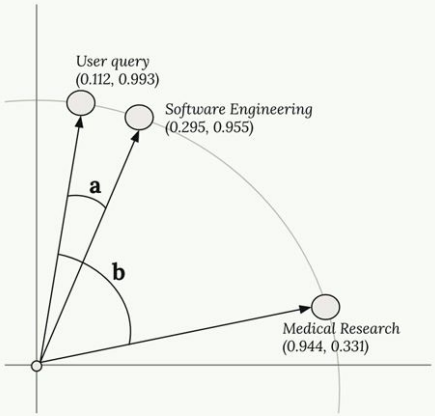
źródło: www.anthropic.com

Jak działa RAG?



źródło: www.anthropic.com

Jak działa RAG?



Cosine Similarity

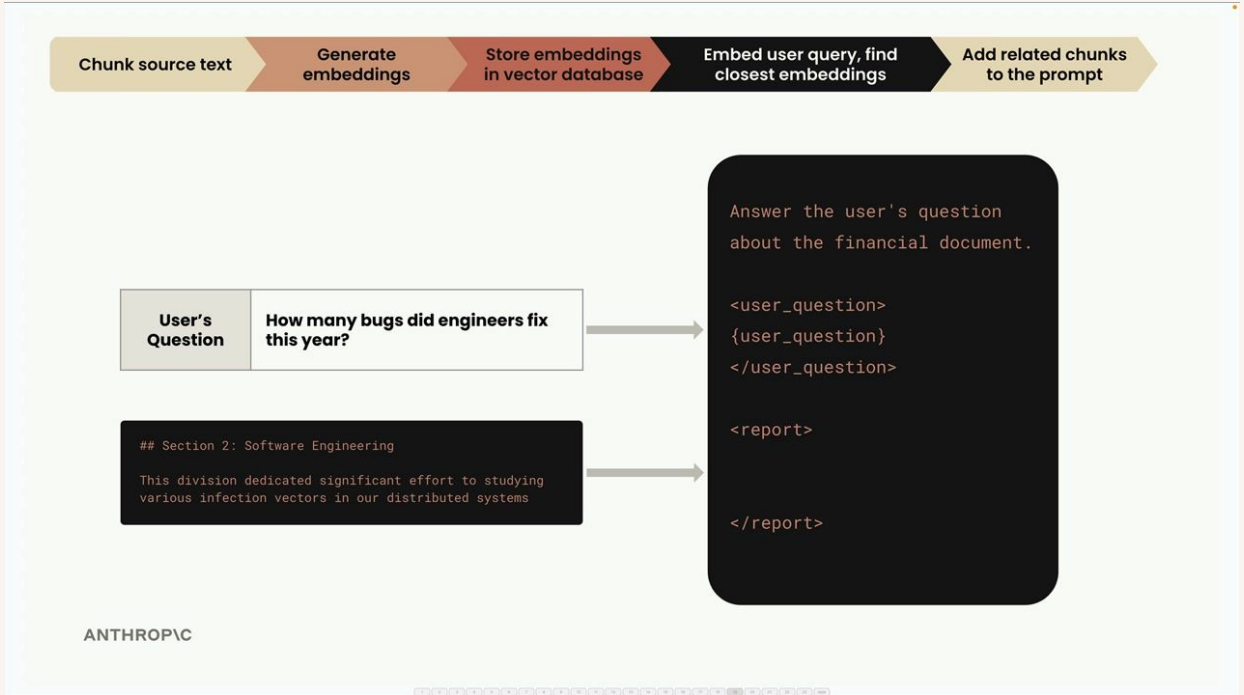
- Cosine of the angle between the two vectors
- If they're in the exact same direction we'd get 1.0
- If perpendicular, 0.0
- If completely opposite, -1.0

$$\cos(a) = \frac{\mathbf{A} \cdot \mathbf{B}}{||\mathbf{A}|| \cdot ||\mathbf{B}||} = \frac{(0.112, 0.993) \cdot (0.295, 0.955)}{||(0.112, 0.993)|| \cdot ||(0.295, 0.955)||} = 0.983$$

$$\cos(b) = \frac{\mathbf{A} \cdot \mathbf{B}}{||\mathbf{A}|| \cdot ||\mathbf{B}||} = \frac{(0.112, 0.993) \cdot (0.944, 0.331)}{||(0.112, 0.993)|| \cdot ||(0.944, 0.331)||} = 0.398$$

źródło: www.anthropic.com

Jak działa RAG?



źródło: www.anthropic.com

Stack technologiczny



Bielik LLM

- **Bielik** to polska rodzina dużych modeli językowych rozwijana przez społeczność open-source SpeakLeash we współpracy z ACK Cyfronet AGH. Modele są trenowane głównie na polskich danych i zoptymalizowane pod język polski, kulturę oraz lokalny kontekst.

Dostępne wersje:

- **Bielik-4.5B-v3**
- Bielik Minitron 7B
- Bielik-1.5B-v3
- Bielik-11B-v2.6

EmbeddingGemma

- **EmbeddingGemma** to otwarty model embeddingowy od Google DeepMind, który zamienia tekst na wektory liczbowe opisujące jego znaczenie. Nie generuje odpowiedzi jak LLM, lecz pomaga wyszukiwać i porównywać treści.

Główne cechy

- 308 mln parametrów
- Obsługa ponad 100 języków
- Niewielkie wymagania sprzętowe
- Możliwość działania lokalnie

Ollama

- **Ollama** to otwartoźródłowe narzędzie umożliwiające uruchamianie modeli AI lokalnie na komputerze. Ułatwia pobieranie, zarządzanie i uruchamianie modeli lokalnie.

Główne cechy

- Uruchamianie modeli AI lokalnie
- Działa na Windows, Linux i macOS
- Prosta instalacja i obsługa (CLI oraz aplikacja desktopowa)
- Wbudowane API do integracji z aplikacjami

BigQuery - Vector Store



- **BigQuery Vector Search** to funkcjonalność BigQuery umożliwiająca przechowywanie i wyszukiwanie embeddingów bezpośrednio w hurtowni danych.

Główne cechy

- Przechowywanie embeddingów w tabelach BigQuery
- Wyszukiwanie podobieństwa wektorowego Integracja z modelami embeddingowymi
- Obsługa systemów RAG i aplikacji AI

Google Cloud Run



- **Google Cloud Run** to usługa serverless w Google Cloud umożliwiająca uruchamianie aplikacji i API w kontenerach bez zarządzania serwerami. Automatycznie skaluje zasoby w zależności od ruchu.

Główne cechy

- Uruchamianie aplikacji w kontenerach Docker
- Automatyczne skalowanie
- Płatność tylko za rzeczywiste użycie
- Integracja z usługami Google Cloud

Część praktyczna



Instrukcja krok po kroku

https://github.com/jasiecky/bielik-workshop

Przygotowanie projektu Google Cloud



- Utworzenie projektu Google Cloud
- Konfiguracja rozliczeń lub kredytów Cloud OnRamp
- Weryfikacja aktywnego projektu i konta w Cloud Shell
- Pobranie repozytorium projektu i konfiguracja środowiska deweloperskiego

Konfiguracja środowiska i usług Google Cloud



- Wczytanie zmiennych środowiskowych
- Aktywacja usług:
- Cloud Run
- Cloud Build
- Artifact Registry
- BigQuery
- Nadanie uprawnień do wywoływania usług Cloud Run

Wdrożenie modelu Bielik



- Analiza konfiguracji wdrożeniowej
- Publikacja modelu Bielik na Cloud Run
- Weryfikacja działania usługi
- Wykonanie pierwszych testowych zapytań do modelu

Wdrożenie modelu EmbeddingGemma

- Analiza konfiguracji wdrożeniowej
- Publikacja modelu embeddingowego na Cloud Run
- Weryfikacja działania usługi
- Generowanie pierwszych embeddingów

Utworzenie wektorowej bazy wiedzy



- Konfiguracja BigQuery Vector Search
- Utworzenie zbioru danych i tabel
- Przygotowanie przestrzeni do przechowywania embeddingów i dokumentów

Wdrożenie warstwy orkiestracji



Analiza aplikacji FastAPI

Publikacja API na Cloud Run

Konfiguracja komunikacji pomiędzy:

- Bielik
- EmbeddingGemma
- BigQuery Vector Search

Zasilenie bazy wiedzy



- Import dokumentów z pliku CSV
- Generowanie embeddingów dla dokumentów
- Zapis treści i wektorów w BigQuery
- Budowa indeksu wyszukiwania semantycznego

Testowanie mechanizmu RAG



- Zadawanie pytań przez endpoint `/ask`
- Wyszukiwanie kontekstu w BigQuery
- Generowanie odpowiedzi przez Bielika z wykorzystaniem odnalezionej wiedzy
- Weryfikacja jakości odpowiedzi

Interfejs API



- `/ingest` – import i indeksowanie wiedzy
- `/ask` – odpowiedzi wspierane przez RAG
- `/ask_direct` – odpowiedzi bez dodatkowego kontekstu
- `/` – interfejs WWW

Interfejs użytkownika

- Porównanie odpowiedzi:
  - Bielik bez RAG
  - Bielik z RAG
- Podgląd dokumentów wykorzystanych jako kontekst
- Demonstracja wpływu wyszukiwania wektorowego na jakość odpowiedzi

Rezultat

Suwerenne rozwiązanie RAG oparte na open-sourcowych modelach i własnej infrastrukturze.



https://eskadra.bielik.ai/

Dołącz do Discord



Dołącz do Discord





Dziękuję za uwagę!